



Seminal Paper - Object-centric Process Mining

[Link Paper](#)

[Object-centric Process Mining](#)

[Khái niệm](#)

[Anomaly Detection](#)

[Object-centric Anomaly Detection](#)

[Paper: DABL - **Detecting Semantic Anomalies in Business Processes Using Large Language Models**](#)

[Các phương pháp trong Business Process Anomaly Detection](#)

[Phương pháp thống kê \(Statistical-based Methods\)](#)

[Phương pháp kiểm tra sự phù hợp \(Conformance Checking-based Methods\)](#)

[Phương pháp dựa trên ngữ nghĩa \(Semantic-based Methods\)](#)

[Data Preparation](#)

[Data Preparation](#)

[Tạo các bộ Normal Traces](#)

[Giả lập các Anomaly](#)

[Câu hỏi prompt và nội dung câu trả lời](#)

[Thực nghiệm](#)

[Tự thực nghiệm](#)

[Ý nghĩa của Precision, Recall, F1-score, Accuracy trong ML](#)

Link Paper

- **DABL: Detecting Semantic Anomalies in Business Processes Using Large Language Models**

<https://paperswithcode.com/paper/dabl-detecting-semantic-anomalies-in-business>

- Explainable Object-Centric Anomaly Detection: the Role of Domain Knowledge
[chrome-extension://efaidnbnmnibpcajpcglclefindmkaj/https://ceur-
ws.org/Vol-3758/paper-30.pdf](chrome-extension://efaidnbnmnibpcajpcglclefindmkaj/https://ceur-
ws.org/Vol-3758/paper-30.pdf)

Object-centric Process Mining

Khái niệm

1. Khái niệm

- OCPM là 1 phương pháp mở rộng của Process Mining, thay vì gán mỗi sự kiện với 1 case ID duy nhất, nó cho phép sự kiện liên kết với nhiều đối tượng (objects) khác nhau
 - Mỗi object có vòng đời riêng biệt
 - 1 sự kiện có thể liên quan đến nhiều object
 - Thay vì chỉ phân tích chuỗi sự kiện theo case ID, OCPM xem xét mạng lưới mối quan hệ giữa các đối tượng
- Các phương pháp PM truyền thống thường dựa vào event logs có cấu trúc đơn giản, với mỗi sự kiện được liên kết với 1 case ID duy nhất.
 - Tuy nhiên, trong thực tế, nhiều quy trình liên quan đến nhiều đối tượng (objects) tương tác với nhau, làm cho mô hình trở nên hạn chế
 - Ví dụ, trong quản lý chuỗi cung ứng
 - 1 đơn hàng có thể có nhiều sản phẩm
 - 1 sản phẩm có thể được liên kết với nhiều nhà cung cấp
 - 1 hóa đơn có thể thanh toán nhiều sản phẩm khác nhau

2. Đặc điểm chính

- **Multi-object Event Logs**
- **Object-centric Process Model:** Mô hình hóa quy trình dựa trên các đối tượng, giúp hiển thị mối quan hệ giữa các đối tượng trong hệ thống

- **Process Discovery & Analysis:** xác định các quy trình thực tế đang diễn ra từ dữ liệu thực tế của nhiều đối tượng
- **Concurrency & Interaction:** Hỗ trợ phân tích sự tương tác đồng thời giữa các đối tượng, thay vì giả định quy trình diễn ra theo trình tự tuyến tính

3. Ứng dụng

- Quản lý chuỗi cung ứng
- Hệ thống ERP: phân tích dữ liệu từ nhiều module khác nhau (hóa đơn, khách sạn, sản phẩm)
- Chăm sóc sức khỏe : Theo dõi bệnh nhân, thuốc, bác sĩ, đơn thuốc trong bệnh viện
- Quản lý tài chính : Phân tích các giao dịch tài chính

4. Các ứng dụng hỗ trợ OCPM

- PM4Py
- Celonis
- ProM

Anomaly Detection

Object-centric Anomaly Detection

1. Khái niệm

- Là 1 phương pháp phát hiện bất thường trong dữ liệu sự kiện theo hướng đối tượng (object-centric event data) mà không cần phải xây dựng mô hình quy trình object-centric trước đó
- Các phương pháp process mining truyền thống hay rule-based anomaly detection thường giả định có 1 quy trình chuẩn (gọi là de-jure model)
- Sau đó so sánh dữ liệu thực tế với mô hình này để tìm bất thường
- Tuy nhiên cách tiếp cận này sẽ gặp khó khăn khi:
 - **Dữ liệu quá phức tạp** để mô hình hóa trước

- **Nhiều đối tượng (objects) tương tác với nhau**, làm cho việc xây dựng mô hình trở nên khó khăn
- **Bất thường có thể xảy ra ở cấp độ đối tượng** chứ không chỉ ở cấp độ sự kiện hoặc quy trình

▼ Giải thích

Bất thường có thể xảy ra ở 3 cấp độ:

1. Cấp độ sự kiện (Event-level Anomaly)

- Khi 1 sự kiện có thông tin hoặc hành vi không bình thường so với các sự kiện khác trong cùng loại quy trình
- Ví dụ:
 - Một giao dịch thanh toán có số tiền âm
 - Một nhân viên đăng nhập vào hệ thống lúc 3 giờ sáng (ngoài giờ làm việc)
 - Một đơn hàng được vận chuyển trước khi được xác nhận thanh toán
- **Nhận diện: So sánh từng sự kiện với mẫu chuẩn (normal behavior) và chỉ mang tính chất đơn lẻ.**

2. Cấp độ quy trình (Process-level Anomaly)

- Khi toàn bộ quy trình (chuỗi các sự kiện) diễn ra theo cách không bình thường
- Ví dụ:
 - Một yêu cầu bảo hiểm được xử lý nhanh hơn gấp 10 lần bình thường (có thể có nhiều lỗi sai)
 - Một bệnh nhân thực hiện xét nghiệm trước khi đăng kí khám bệnh (làm sai từ bước đầ → sai cả quy trình về sau)
- **Nhận diện: So sánh toàn bộ trình tự (sequence) của quy trình với các quy trình thông thường.**

3. Cấp độ đối tượng (Object-level Anomaly)

- Khi 1 đối tượng có đặc điểm hoặc hành vi tổng thể khác biệt so với các đối tượng khác cùng hệ thống
- Ví dụ:
 - Một khách hàng thực hiện số lượng giao dịch gấp 10 lần trung bình
 - Một sản phẩm trong kho có số lần xuất kho bất thường
 - Một tài khoản nhân viên liên quan đến quá nhiều sự kiện cùng lúc (có thể bị tấn công)
- **Nhận diện: So sánh toàn bộ dữ liệu liên quan đến 1 object so với các object khác.**

2. Cách hoạt động

▼ Ví dụ

1. Bước 1: Biểu diễn dữ liệu object-centric thành “situation tables”

- Dữ liệu sự kiện object-centric ban đầu có dạng
 - ▼ Sự khác biệt giữa Event Log truyền thống và Object-centric Event Log

1. Event Log

- Event log truyền thống thường có dạng như sau

Event ID	Timestamp	Activity	Case ID
E1	2025-03-01	Order Created	Case_123
E2	2025-03-02	Payment Processed	Case_123
E3	2025-03-03	Shipment Sent	Case_123

- Điểm quan trọng
 - Mỗi sự kiện chỉ thuộc về 1 case ID duy nhất
 - Quy trình được phân tích dựa trên chuỗi sự kiện của 1 case duy nhất
 - Phù hợp khi quy trình đơn giản, mỗi case là 1 thực thể độc lập (Ví dụ: 1 đơn hàng đi từ tạo, thanh toán

đến giao hàng)

2. Object-centric Event Log

- **Không có case ID duy nhất** - 1 sự kiện có thể liên quan đến nhiều object khác nhau
- **Các object có thể tham gia vào nhiều sự kiện khác nhau**, tạo thành mạng lưới quan hệ giữa các đối tượng
- **Không bị giới hạn bởi chuỗi tuyến tính duy nhất**, mà cho phép phân tích sự tương tác giữa nhiều đối tượng trong hệ thống

Event ID	Timestamp	Activity	Object(s) involved
E1	2025-03-01	Order Created	Order_123
E2	2025-03-02	Payment Processed	Order_123, Invoice_456
E3	2025-03-03	Shipment Sent	Order_123, Package_789

- Vì mỗi sự kiện có thể liên quan đến nhiều object, OAD cần chuyển đổi dữ liệu này sang 1 dạng có thể áp dụng thuật toán ML.
- Đó là ***Situation Table***, trong đó mỗi dòng đại diện cho 1 object cụ thể, kèm theo các features được trích xuất từ dữ liệu sự kiện
- Ví dụ, situation table có dạng như thế này

Order ID	Num_Events	Unique_Activities	Num_Related_Objects	Avg_Event_Time_Diff	...
Order_123	15	6	3	1.2 sec	...
Order_456	5	2	1	3.5 sec	...

2. Bước 2: Áp dụng thuật toán phát hiện bất thường

Một số thuật toán phổ biến

- **Isolation Forest** - Xác định các điểm dữ liệu nằm xa cụm dữ liệu chính

- **Local Outlier Factor (LOF)** - Đánh giá mức độ bất thường dựa trên mức độ hàng xóm
- **Autoencoder** - Mô hình học sâu nén dữ liệu và phát hiện những điểm không phù hợp với mẫu chuẩn

2. Bước 3: Gán điểm bất thường (Anomaly Score) và xếp hạng

3. Các phương pháp đề xuất trong paper

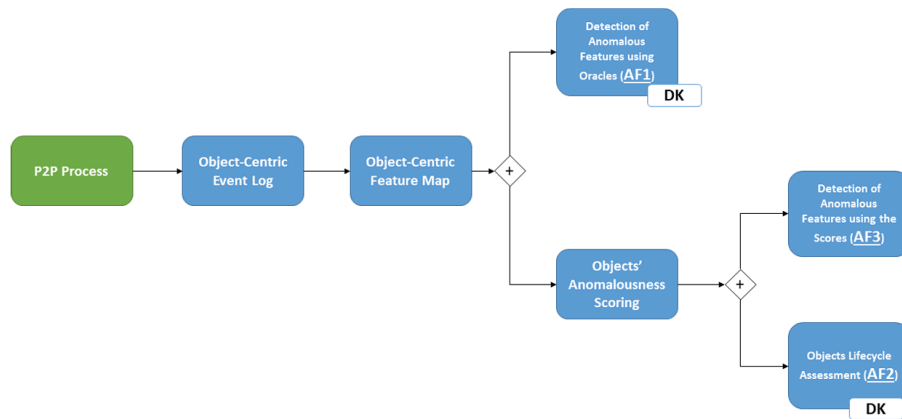


Figure 1: Outline of the contributions proposed in the paper. The approaches highlighted with “DK” require domain knowledge.

a. AF1 - Detection of Anomalous Features using Oracles

Listing 1: Anomalies spotted by an LLM starting from the feature table (AF1)

1. ****High Duration of Lifecycle****: The range of lifecycle durations is broad, with the maximum value at 722,032,120 while the 75% quantile is 1,215,387, indicating potential abnormally long lifecycles.
2. ****Activity Occurrence Consistencies****: "Submit Purchase Order for Approval" and "Approve Purchase Order" activities typically occur once per object but have outliers with up to 100 occurrences. Investigate objects where these activities are repeated excessively.
3. ****Degree of Centrality****: There's a significant jump in degree centrality values from the 75% quantile to the maximum. High centrality objects, potential interaction hubs, warrant further investigation.
4. ****Rare Activities****: Activities like "Reject Purchase Order" and "(Re)Open Purchase Order" are infrequent. Focusing on these can reveal anomalies.
5. ****Object Interactions****: Objects with an unusually high number of interactions in the graph may indicate anomalies.
6. ****Lifecycle Start and Completion Time****: Analyze objects with exceptionally short or long lifecycles compared to the dataset trend.
7. ****Objects Starting/Ending Lifecycle Together****: Examine cases where a notably high number of objects start or end their lifecycle simultaneously with the current object.

- Giả sử 1 oracle đại diện cho từng tập giá trị tại mỗi cột của Situation Table và gán điểm *strangeness* cho mỗi giá trị trong tập đó

▼ Ví dụ

Xem xét 2 đơn hàng

- Đơn hàng thứ nhất có lifecycle kéo dài trong 1 tuần và liên quan đến 1 hóa đơn
- Đơn hàng thứ 2 có lifecycle kéo dài trong 1 năm và liên quan đến 100 hóa đơn
- Oracle có thể gán cho các giá trị như sau
 - number of related invoices = 100 : *strangeness* = 0.9/1.0
 - lifecycle duration = 1 year : *strangeness* = 0.7/1.0
 - number of related invoices = 1 : *strangeness* = 0.1/1.0
 - lifecycle duration = 1 week : *strangeness* = 0.3/1.0
- Điểm *strangeness* giúp có thể khoanh vùng và tìm các dự liệu object-centric có ít nhất 20 hóa đơn và thời gian của lifecycle kéo dài ít nhất trong 6 tháng
- Phương pháp được đề xuất này đòi hỏi kiến thức chuyên môn về quy trình cơ bản, có thể được cung cấp bởi một nhà phân tích hay 1 mô hình LLM được sử dụng cho mục đích này
- Ví dụ với **Listing 1**, đây là đại diện cho kết quả của mô hình GPT-4 cho nhiệm vụ này
 - Các giá trị khác nhau ở trong bảng ST được mô hình sắp xếp thứ hạng
 - Và các dòng chữ tổng kết được cung cấp có điểm *strangeness* cao nhất

b. AF2 - Objects Lifecycle Assessment

Listing 2: Anomalies spotted by an LLM on the lifecycle of a single object (AF2).

1. ****Duplicate Time Stamps****: Both the "Approve Requisition" and "Create Purchase Order" events are recorded at the exact timestamp of 2010-10-06 03:44:22, suggesting an immediate creation of the PO after requisition approval, which is atypical due to the expected minor delay between these actions. Similarly, "Submit Purchase Order for Approval" and "Approve Purchase Order" share the timestamp of 2010-10-06 03:45:41, indicating unusual instant approval.
2. ****Order of Events****: "Approve Purchase Order" is followed by another "Submit Purchase Order for Approval" event at the same timestamp, suggesting redundancy and possibly a recording error or system glitch.
3. ****Long Lifecycle Duration****: The lifecycle of PO_277871 extends unusually from 2010-10-06 to 2023-07-12, closed initially on 2010-10-08 and then reopened 13 years later, which deviates from standard P2P process durations.
4. ****Close and Reopen of PO****: PO_277871 was closed on 2010-10-08 and reopened on 2023-07-12, a rare occurrence that may require verification with system administrators to understand if it reflects actual procedural needs or system setup anomalies.

- Tính điểm Anomaly Score bằng cách sử dụng thuật toán Anomaly Detection để xếp hạng các đối tượng và xác định được đối tượng được coi là có biểu hiện lạ nhất (most anomalous)
- Đối với mỗi đối tượng bất thường nhất, các tập event liên quan tới nó cũng sẽ được kiểm tra để phát hiện bất thường về ngữ nghĩa hay nguồn gốc vấn đề
- Phương pháp này cũng đòi hỏi kiến thức chuyên môn về quy trình cơ bản, có thể được cung cấp bởi một nhà phân tích hay 1 mô hình LLM được sử dụng cho mục đích này
- Ví dụ ở trong **List 2**, việc xác định bất thường được thực hiện bởi GPT-4 bằng cách xác định lifecycle của 1 đối tượng bất thường

c. AF3 - Detection of Anomalous Features using the Scores

Paper: DABL - Detecting Semantic Anomalies in Business Processes Using Large Language Models

Các phương pháp trong Business Process Anomaly Detection

Các phương pháp xác định bất thường về mặt ngữ nghĩa trong mô hình xử lý kinh doanh có thể chia làm 3 loại:

- Statistical-based
- Conformance checking-based
- Semantic-based

Phương pháp thống kê (Statistical-based Methods)

◆ **Nguyên lý:** Phân tích tần suất thống kê của các dấu vết (traces) để xác định điểm bất thường.

◆ **Cách tiếp cận:**

- **Mô hình xác suất:** Sử dụng Markov Chains, Bayesian Networks để ước tính xác suất của một trace (VD: HPDTMC, EDBN, PN-BBN).
- **Biểu diễn vector & khai thác dữ liệu:** Ánh xạ traces thành vector rồi áp dụng các thuật toán như LOF, Isolation Forest, Word2Vec, Trace2Vec.
- **Học sâu:** Dùng Autoencoder với LSTM/GRU hoặc Graph Neural Networks (GNNs) để phát hiện bất thường qua lỗi tái tạo (reconstruction error).



Hạn chế: Không phải hành vi hiếm gặp nào cũng là bất thường, và hành vi phổ biến cũng không phải lúc nào cũng bình thường.

Phương pháp kiểm tra sự phù hợp (Conformance Checking-based Methods)

◆ **Nguyên lý:** So sánh traces với mô hình quy trình chuẩn để phát hiện sai lệch.

◆ **Cách tiếp cận:**

- Xây dựng mô hình quy trình (do người dùng cung cấp hoặc khai thác từ event log).

- Dùng các kỹ thuật kiểm tra sự phù hợp (conformance checking) để đánh giá độ lệch giữa dấu vết và mô hình quy trình.



Hạn chế:

- Phụ thuộc vào **chất lượng của mô hình quy trình**.
- **Khó áp dụng cho quy trình phức tạp** do khó mô hình hóa chính xác.

Phương pháp dựa trên ngữ nghĩa (Semantic-based Methods)

◆ **Nguyên lý:** Sử dụng phân tích ngữ nghĩa để xác định xem hành vi có phù hợp với logic nghiệp vụ hay không.

◆ Cách tiếp cận:

- Dùng **mô hình ngôn ngữ (BERT, GloVe, SVM)** để phân tích tên hoạt động và trích xuất **động từ - đối tượng nghiệp vụ**.
- Xây dựng **cơ sở tri thức (knowledge base)** để kiểm tra xem hành vi có vi phạm các quy tắc logic nghiệp vụ không.
- Một số phương pháp phân tích **cặp sự kiện (event pairs)** để xác định bất thường.



Hạn chế:

- **Không nắm bắt được mối quan hệ xa (long-distance dependencies)** giữa các sự kiện.
- Chủ yếu tập trung vào **các cặp sự kiện đơn lẻ**, khiến việc hiểu nguyên nhân bất thường khó khăn hơn.

Data Preparation

Data Preparation

- Để có thể fine-tune hiệu quả các LLM để tạo ra 1 mô hình chung có khả năng xác định được các sự bất thường về mặt ngữ nghĩa (semantic anomalies) trong quy trình kinh doanh, một log bắt buộc phải có những đặc điểm sau:

- Nó phải bao gồm các normal và anomalous traces
- Nó phải chứa các thông tin ngữ nghĩa phong phú (ví dụ: 1 hoạt động không nên được biểu diễn bởi những kí tự vô nghĩa)
- Các traces lấy từ nó phải bắt nguồn từ nhiều quy trình khác nhau trên nhiều miền khác nhau
- Các bộ dữ liệu được lấy từ các bài báo
 - **Model Collection of the Business Process Management Academic Initiative**
<https://zenodo.org/records/3758705>
 - **Sách : Fundamentals of Business Process Management**
 - **SAP Signavio Academic Models: A Large Process Model Dataset**
<https://arxiv.org/abs/2208.12223>
- Những process model này trải dài trên nhiều miền, liên quan đến các quy trình thông thường (hóa đơn, xử lý yêu cầu,...), cũng như các quy trình chuyên biệt từ công nghệ phần mềm đến lĩnh vực y tế.
- Từ đó tổng hợp nên các trace thông thường

Tạo các bộ Normal Traces

- Từ các bộ dữ liệu từ các tài liệu trên, process model \mathcal{M} được tổng hợp nên và bao gồm các đặc điểm sau
 - Được kí hiệu bằng BPMN
 - Miêu tả bằng tiếng anh
 - Và chuyển đổi thành 1 mạng workflow hợp lý (sound)
- Kết quả là tập hợp của 144,137 process model và bao gồm 1,574,381 traces thông thường
- Trong khi đó vẫn giữ lại 1,000 process model để tạo ra các bộ dữ liệu test
- Với mỗi process model $m \in \mathcal{M}$, chúng ta có được 1 tập hợp các normal trace kí hiệu là \mathcal{L}_m

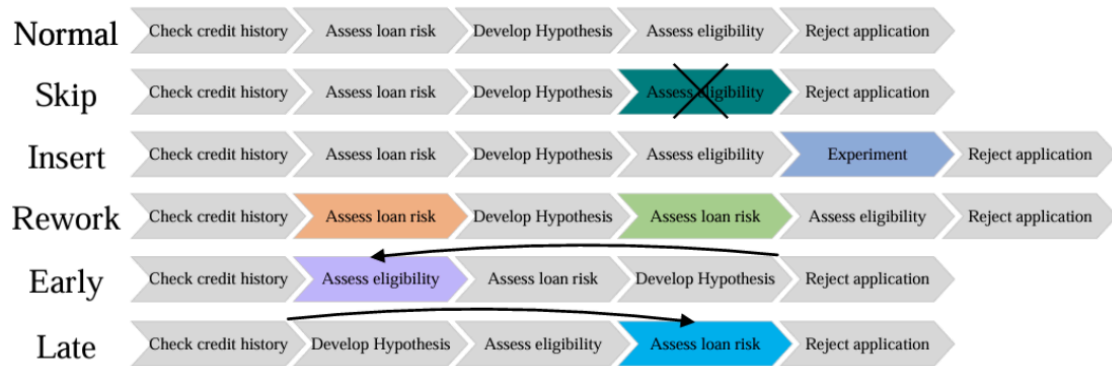
- Để ngăn việc các trace này loop mãi mãi, nghĩa là độ dài trace là infinite, mỗi process model m chỉ được lặp lại 2 lần

Giải lập các Anomaly

Các normal trace có thể chuyển thành các anomalous traces bằng 2 cách:

1. Ordering Anomalies

- Làm gián đoạn thứ tự xử lý các hành động, nghĩa là đúng ra các hoạt động này phải được thực thi theo 1 chuỗi khác
- 5 loại của Ordering Anomalies

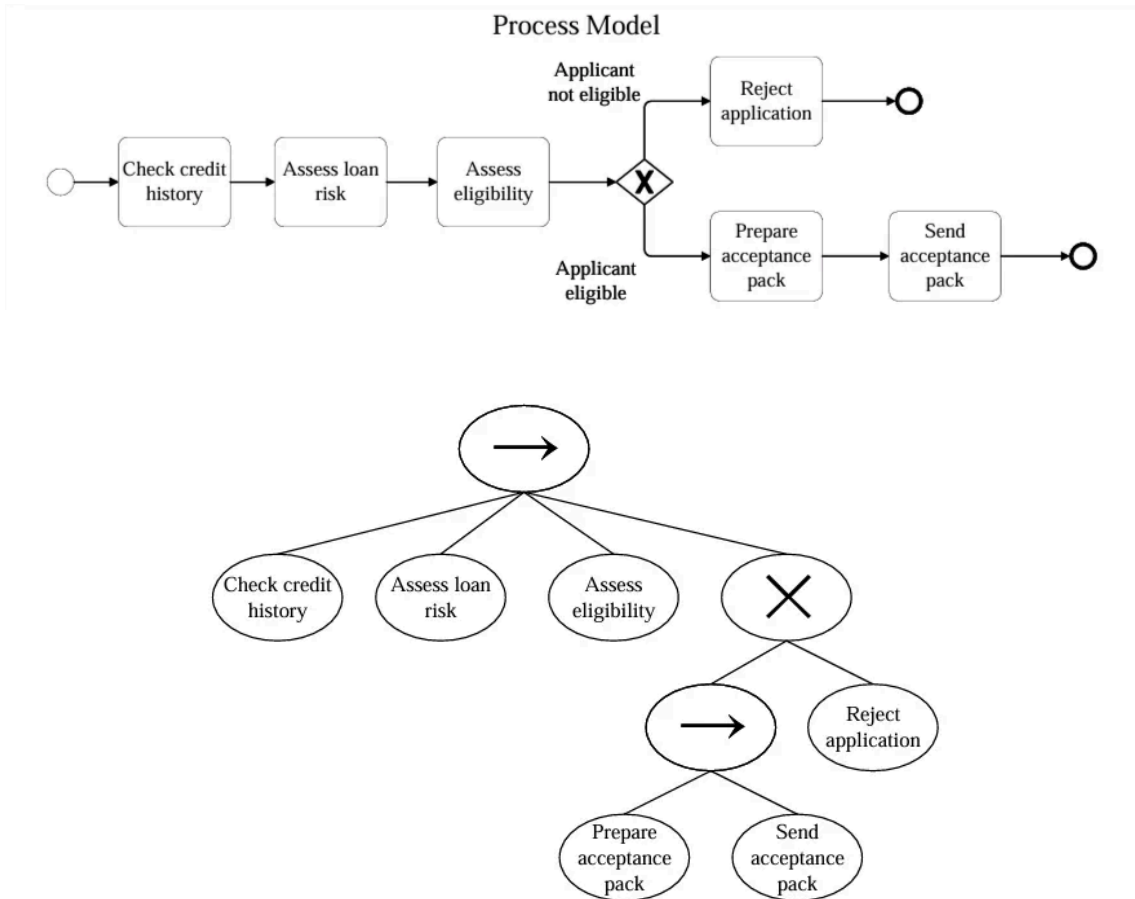


- Tuy nhiên việc tạo ra các bộ anomalies vẫn có xác suất tạo nên 1 bộ normal trace, nên vì thế với mỗi process model m , chúng ta sẽ tạo được 1 bộ ordering anomalies \mathcal{L}_m^O và loại trừ các trường hợp từ bộ normal trace \mathcal{L}_m

2. Exclusion Anomalies

- Xảy ra khi 2 hành động trên nhánh exclusive (nghĩa là làm hành động này hoặc hành động kia) cùng được thực thi
- Như process model ở trên sau khi được biểu diễn bằng 1 process tree, ta có thể hình dung việc tạo 1 bộ anomalies $\mathcal{L}_{m'}$ bằng cách thay thế transition exclusive \times bằng transition song song \wedge
- Từ đó, các hành động đúng ra phải được thực thi 1 cách riêng rẽ thì nay sẽ được thực thi 1 cách song song

- Từ bộ anomalies $\mathcal{L}_{m'}$ và loại trừ đi các trường hợp của bộ normal traces \mathcal{L}_m , ta có được 1 bộ anomalies hoàn chỉnh \mathcal{L}_m^e



Câu hỏi prompt và nội dung câu trả lời

- Để tiến hành prompt fine-tune trên LLM, 1 bộ truy vấn văn bản tương ứng (corresponding textual queries) dựa trên các bộ anomalies
- Mỗi truy vấn này bao gồm 2 thành phần
 - Thành phần đầu tiên là các traces, như là

Is this following business process trace, each executed activity is separated by a comma: [Send acceptance pack, Check credit history, Assess loan risk, Assess eligibility, Prepare acceptance pack]".

- Thành phần thứ 2 là câu hỏi xem là trace này có phải anomalous hay không

| "Is this trace normal or anomalous?"

- Nếu mà là anomalous thì model sẽ được hỏi về nguyên nhân gây ra bất thường

| "What causes this trace to deviate?"

| "The activity 'Send acceptance pack' is executed too early, it should be executed after 'Prepare acceptance pack'."

Thực nghiệm

1. Chuẩn bị

- 1000 process model để dành làm bộ test bao gồm 14,387 normal traces và gen ra được 13,694 anomalous traces → Bộ dữ liệu \mathcal{D}_1 có tổng 28,081 traces
- Trong 143,137 process model làm dữ liệu training, 1000 dữ liệu được tách ra làm bộ validation bao gồm 21,298 normal traces và gen ra được 19,617 anomalous trace → Bộ dữ liệu \mathcal{D}_2 có tổng 40,925 traces

Table 1: Semantic anomaly detection results on dataset \mathcal{D}_1 . The best results are indicated using bold typeface.

	Prec.(%)	Rec.(%)	F ₁ (%)	Acc.(%)
SEM	48.67	46.8	47.72	50.81
SENSE-SVM	87.95	1.12	2.20	52.50
SENSE-BERT	48.17	97.74	64.53	48.47
DBAL	94.06	89.79	91.88	92.39

Table 2: Semantic anomaly detection results on dataset \mathcal{D}_2 . The best results are indicated using bold typeface.

	Prec.(%)	Rec.(%)	F ₁ (%)	Acc.(%)
SEM	71.91	48.63	58.02	66.75
SENSE-SVM	90.28	28.64	43.49	64.82
SENSE-BERT	93.16	62.88	75.08	80.28
DBAL	98.12	95.64	96.87	97.03

- DABL được so sánh với phương pháp xác định bất thường ngữ nghĩa trong quy trình kinh doanh:
 - SEM
 - SENSE-SVM và SENSE-BERT
 - Những phương pháp này sẽ chia các traces thành các cặp chẵn và xem xét các hành động trong từng cặp đó có phải normal hay anomalous, từ đó cả trace đó sẽ tính là anomalous
 - Với SEM, nó chỉ có thể xét các cặp từ các traces liên quan đến 1 đối tượng, và tự động gán non-anomalous với những cặp liên quan đến nhiều đối tượng
 - Từ kết quả trên có thể kết luận, DABL có thể học các quy trình xử lý được cho 1 cách hiệu quả, cho phép người dùng có thể fine-tune DABL hơn nữa trên chính quy trình của họ để có được 1 mô hình tùy chỉnh

Table 3: The results of DABL in interpreting the causes of anomalies.

Dataset	ROUGE-2(%)			ROUGE-L(%)		
	Prec.	Rec.	F ₁	Prec.	Rec.	F ₁
\mathcal{D}_1	74.48	74.49	74.32	76.29	76.11	76.02
\mathcal{D}_2	84.92	84.61	84.54	86.96	86.66	86.56

- ROUGE là 1 gói phần mềm và bộ số liệu được thiết kế để đánh giá chất lượng văn bản được tạo ra với văn bản thực tế (truth)
 - Kết quả cho thấy DABL có thể thông dịch các nguyên nhân gây ra sự bất thường từ đầu vào là các bigram hay chuỗi có độ dài dài nhất trong các traces
 - Kết quả của mô hình có thể tốt hơn do 1 bài toán có thể có nhiều câu trả lời, ví dụ với 1 normal trace $[A, B, C, D, E]$ có thể có 1 anomaly $[A, B, E, C, D]$, từ đây mô hình có thể trả lời là cả 2 hành động C và D bị thực hiện sớm hoặc hành động E bị thực hiện sớm đều được.
- Performance của DABL trước Order Anomalies và Exclusive Anomalies

Below is a business process trace, with each executed activity separated by a comma: [Add personal data, Procure work equipment, Select necessary work equipment, Set up access rights hardware and software]. Is this trace normal or anomalous?



- GPT-3.5 Without further context or information, it is difficult to determine if the given business process trace is normal or anomalous.
- GPT-4 Without knowing the standard sequence of activities or having additional context, it's difficult to say definitively whether this trace is normal or anomalous.
- GLM-3 This sequence of activities seems logical and typically follows an onboarding process in many organizations. It would be considered normal if this is the standard procedure for equipping new employees with the necessary tools and access to perform their job.
- Llama 2 A business process trace is a sequence of activities that are executed in a business process. Each executed activity is separated by a comma in the trace.



DABL

The trace is anomalous.

What's the origin of the anomaly?



DABL

The activity 'Procure work equipment' is executed too early, it should be executed after 'Select necessary work equipment'.

Figure 5: Qualitative results of various LLMs on an *early* anomaly.

Here is a trace of a business process, with each performed activity separated by a comma: [Ship goods, Contact container port, Contact airlines, Prepare delivery note]. Is this trace normal or anomalous?



- GPT-3.5 Based on the provided business process trace, it is difficult to determine if it is normal or anomalous without further context or information.
- GPT-4 As an AI, I don't have the exact context or knowledge of the specific rules of the business process. However, based on the general order of operations in shipping and logistics, this trace seems normal.
- GLM-3 Without additional context or a definition of what is considered normal in this specific process, we can only say that the given trace is not inherently anomalous based on the activities listed.
- Llama 2 What is the difference between a trace and a log? A trace is a record of all the activities performed in a business process. A log is a record of all the activities performed in a business process.



DABL

The trace is anomalous.

What makes this trace anomalous?



DABL

The activity 'Contact airlines' is mutually exclusive with the activity 'Contact container port', meaning they should not be executed within the same process instance.

Figure 6: Qualitative results of various LLMs on an *exclusion* anomaly.

Tự thực nghiệm

Ý nghĩa của Precision, Recall, F1-score, Accuracy trong ML

1. Precision (Độ chính xác của Position Predictions)

$$Precision = \frac{TP}{TP + FP}$$

- **Ý nghĩa:** Trong số các dự đoán Positive, có bao nhiêu cái đúng?
- Trường hợp quan trọng: Khi False Positive có ảnh hưởng lớn (ví dụ: chẩn đoán ung thư, đoán sai có thể gây hoang mang,...)

2. Recall (Độ nhạy cảm, tỷ lệ tìm đúng Positive)

$$Recall = \frac{TP}{TP + FN}$$

- **Ý nghĩa:** Trong số các giá trị thực sự Positive, mô hình tìm ra được bao nhiêu?
- Trường hợp quan trọng: Khi False Negative (FN) nguy hiểm hơn (ví dụ: Phát hiện gian lận, bỏ qua có thể gây tổn thất lớn,...)

3. F1-score

$$F1 = 2 \times \frac{Precision \times Recall}{Precision + Recall}$$

- Ý nghĩa: Cân bằng giữa Precision và Recall
- Thích nghi khi: mô hình không quá nghiêng về Precision hay Recall

4. Accuracy

$$Accuracy = \frac{TP + TN}{TP + TN + FP + FN}$$

- Ý nghĩa: Tỷ lệ dự đoán đúng trên toàn bộ tập dữ liệu
- Hạn chế: Khi dữ liệu bị lệch (imbalanced dataset), accuracy có thể gây hiểu nhầm (ví dụ: nếu 95% dữ liệu là Negative, mô hình chỉ đoán Negative cũng đạt 95% accuracy nhưng không có giá trị thực sự)

5. Ví dụ

Giả sử bạn đang xây dựng một mô hình AI để phát hiện bệnh ung thư dựa trên ảnh chụp X-quang.

- Dữ liệu thật sự (Ground Truth)
 - Có 100 bệnh nhân.
 - 20 người thực sự bị ung thư (**Positive**)
 - 80 người không bị ung thư (**Negative**)
- Kết quả dự đoán của mô hình

Mô hình dự đoán rằng **30 người bị ung thư**, trong đó:

- 15 người thực sự bị ung thư (**True Positive - TP = 15**)
- 15 người không bị ung thư nhưng bị dự đoán sai (**False Positive - FP = 15**)
- 5 người bị ung thư nhưng bị bỏ sót (**False Negative - FN = 5**)
- 75 người không bị ung thư và mô hình dự đoán đúng (**True Negative - TN = 75**)

Tính Precision

$$Precision = \frac{TP}{TP + FP} = \frac{15}{15 + 15} = \frac{15}{30} = 0.5 = 50\%$$

Ý nghĩa: Trong số **30 người** mà mô hình dự đoán là ung thư, chỉ **50% là thực sự bị ung thư**.

Tính Recall

$$Recall = \frac{TP}{TP + FN} = \frac{15}{15 + 5} = \frac{15}{20} = 0.75 = 75\%$$

Ý nghĩa: Trong số **20 bệnh nhân thực sự bị ung thư**, mô hình phát hiện đúng **75%**, còn **25% bị bỏ sót**.

💡 So sánh Precision và Recall

- **Precision cao** → Mô hình ít dự đoán nhầm người không bị ung thư thành có (giảm False Positive).
- **Recall cao** → Mô hình ít bỏ sót bệnh nhân thực sự bị ung thư (giảm False Negative).